

On cherche à estimer  $V$  (paramètre constant).

On relève la position du véhicule le long du rail à des instants  $t_n = nT$ .

On considère  $Y_n = nTV + B_n$ , avec  $B_n \sim N(0, \sigma_B^2)$ .

À  $t_n = t_0 = 0$ , le mobile se trouve en 0.

## TD1 Expériences

1. On trace la droite qui passe au mieux par tous les points et l'origine, on trouve une pente d'environ 1 m/s.  
L'hypothèse "bruit blanc" a l'air de marcher mais ne pas faire de conclusion rapide (on n'a que 10 mesures).

2. La "meilleure droite" ne passe pas par l'origine. Les causes possibles sont : un bruit non centré, ou une position non nulle à  $t_0 = 0$ . On a l'impression que le bruit est corrélé, mais on ne peut pas tirer de conclusion.

3. Pour obtenir la ddp de  $\hat{V}$  :

- Méthode basée sur l'expérience : chaque jeu d'observation donne  $\hat{v}_i$  et on trace l'histogramme (voir TP d'initiation à Matlab).
- Méthode de changement de variable : ddp de  $B_n$ , puis ddp de  $Y_n$  et enfin (passage difficile) ddp de  $\hat{V}$ .

Remarque :  $\hat{V} \sim N(m_{\hat{v}}, \sigma_{\hat{V}}^2)$

- 1er estimateur (non biaisé) :  $m_{\hat{v}} = 1m/s$  et  $\sigma_{\hat{V}} = 0,08m/s$
- 2ème estimateur (non biaisé) :  $m_{\hat{v}} = 1m/s$  et  $\sigma_{\hat{V}} = 0,04m/s$ , meilleur estimateur car meilleur écart-type.

### TD1.1 Estimateur empirique

Dans cette partie,  $Y_n = nTV + B_n$  avec bruit faible, donc  $V = \frac{y_n}{nT}$ .

1. On mesure  $y_n$ .

$$\hat{V}_{emp} = \frac{Y_n}{nT}$$

$$E[\hat{V}_{emp}] = \frac{E[Y_n]}{nT} = \frac{E[nTV + B_n]}{nT} = V + \frac{E[B_n]}{nT} = V$$

donc l'estimateur est non biaisé.

$$\sigma_{\hat{V}_{emp}}^2 = E[(\hat{V}_{emp} - m_{\hat{V}_{emp}})^2] = E[(\frac{Y_n}{nT} - V)^2] = E[(\frac{nTV + B_n}{nT} - V)^2] = \frac{1}{(nT)^2} E[B_n^2]$$

$$\sigma_{\hat{V}_{emp}} = \frac{\sigma_B}{nT}$$

Ainsi, pour minimiser  $\sigma_{\hat{V}_{emp}}$ , on prend  $n = N$  (la plus grande mesure).

2. On dispose de  $N$  mesures  $y_1, \dots, y_N$

$$\hat{V}_{emp} = \frac{\sum_n \frac{y_n}{nT}}{N}$$

L'estimateur n'est pas biaisé car :

$$E[\hat{V}_{emp}] = \frac{\sum_n \frac{E[Y_n]}{nT}}{N} = V$$

Écart-type de l'estimateur :

$$\begin{aligned}\sigma_{\hat{V}_{emp}}^2 &= E[(\hat{V}_{emp} - m_{\hat{V}_{emp}})^2] \\ &= E[(\hat{V}_{emp} - V)^2] \\ &= E\left[\left(\frac{\sum_n V + \frac{B_n}{nT}}{N} - \frac{NV}{N}\right)^2\right] \\ &= \frac{1}{N^2} E\left[\left(\sum_n \frac{B_n}{nT}\right)^2\right] \\ &= \frac{1}{(NT)^2} E\left[\left(\sum_n \frac{B_n}{n}\right)^2\right] \\ &= \frac{1}{(NT)^2} \left(\sum_n \frac{E[B_n^2]}{n^2} + \sum_{n \neq m} \frac{E[B_n B_m]}{nm}\right)\end{aligned}$$

Le bruit est blanc, donc les  $E[B_n B_m] = 0$

$$\begin{aligned}\sigma_{\hat{V}_{emp}}^2 &= \frac{\sigma_B^2}{(NT)^2} \sum_n \frac{1}{n^2} \\ \sigma_{\hat{V}_{emp}} &= \frac{\sigma_B}{nT} \sqrt{S_1}\end{aligned}$$

Or,  $\frac{\sigma_B}{nT} \sqrt{S_1} > \frac{\sigma_B}{nT}$ . Cela signifie que notre estimateur avec 1 mesure est "meilleur" que celui avec  $n$  mesures. On est triste d'avoir considéré les premières mesures qui sont très sensibles, comme nous, mais au bruit.

## TD1.2 Préliminaires

$V$  grandeur certaine mais inconnue,  $Y_n = nTV + B_n$  et  $B_n = N(0, \sigma_B^2)$ .

1. Moyenne de  $Y_n$  :  $m_n = E[Y_n] = nTV$ .

Écart-type de  $Y_n$  :  $\sigma_n^2 = E[(Y_n - m_n)^2] = E[B_n^2]$  donc  $\sigma_n = \sigma_B$

Coefficient de corrélation :

$$\rho_{mn} = \frac{E[(Y_n - m_n)(Y_m - m_m)]}{\sigma_n \sigma_m} = \frac{E[B_n B_m]}{\sigma_B^2} = \begin{cases} 1 & \text{si } m = n \\ 0 & \text{si } m \neq n \end{cases} = \delta_{n-m}$$

2. Par changement de variables aléatoires si ça t'amuse,

$$f_{Y_n}(y_n) = f_{B_n}(y_n - nTV) = \frac{1}{\sqrt{2\pi\sigma_b^2}} e^{-\frac{(y_n - nTV)^2}{2\sigma_b^2}}$$

Le caractère gaussien se conserve par transformation linéaire, i.e. toute combinaison linéaire de VA suivant une loi gaussienne suit aussi une loi gaussienne. Attention, ne pas sommer les ddp.

Les  $Y_i$  étant indépendants (car les  $B_i$  sont indépendants car blancs) :

$$f_{Y_1, \dots, Y_n}(y_1, \dots, y_n) = \prod_{i=1}^N f_{Y_i}(y_i) = \frac{1}{(2\pi)^{N/2} \sigma_B^N} \exp\left(-\frac{1}{2} \frac{\sum_n (y_n - nTV)^2}{\sigma_B^2}\right)$$

$$f_{\mathbf{Y}}(\mathbf{y}) = \frac{1}{(2\pi)^{N/2} \sigma_B^N} \exp\left(-\frac{1}{2} \frac{(\mathbf{y} - E[\mathbf{y}])^T (\mathbf{y} - E[\mathbf{y}])}{\sigma_B^2}\right)$$

Rappel : la décorrélation n'implique pas l'indépendance, il faut le caractère "gaussiens dans leur ensemble".

### TD1.3 Estimateur des moindres carrés

1. L'estimateur au sens des moindres carrés de  $V$  est :

$$\hat{v}_{MC} = \arg_V \min \sum_{n=1}^N (y_n - nTV)^2$$

En posant  $J_{MC} : V \rightarrow \sum_{n=1}^N (y_n - nTV)^2$ ,  $J_{MC}$  est une parabole (concavité tournée vers le haut). On a alors une condition nécessaire et suffisante à la minimisation :

$$\begin{aligned} \frac{dJ_{MC}}{dV} \Big|_{V=\hat{V}_{MC}} = 0 &\Leftrightarrow \sum_{n=1}^N 2(-nT)(y_n - nTV) = 0 \\ &\Leftrightarrow \sum_{n=1}^N ny_n - \hat{v}_{MC} T \sum_{n=1}^N n^2 = 0 \\ &\Leftrightarrow \hat{v}_{MC} = \frac{\sum_n ny_n}{T \sum_{n=1}^N n^2} \\ &\Leftrightarrow \hat{V}_{MC} = \frac{\sum_n nY_n}{TS_2} \end{aligned}$$

2. Calculons la moyenne de l'estimateur.

$$m_{MC} = E[\hat{v}_{MC}] = \frac{\sum_n nE[Y_n]}{TS_2} = \frac{\sum_n n(nTV)}{TS_2} = V$$

L'estimateur non biaisé.

On s'intéresse à son écart-type.

$$\begin{aligned} \sigma_{MC}^2 &= E[(\hat{V}_{MC} - m_{MC})^2] \\ &= E[(\hat{V}_{MC} - V)^2] \\ &= E\left[\left(\frac{\sum_n nY_n}{TS_2} - V\right)^2\right] \\ &= E\left[\left(\frac{\sum_n n^2(TV + nB_n) - TV \sum_n n^2}{TS_2}\right)^2\right] \\ &= E\left[\left(\frac{\sum_n nB_n}{TS_2}\right)^2\right] \end{aligned}$$

Comme les  $B_n$  sont décorrélés, les doubles produits sont tous nuls

$$\sigma_{MC}^2 = \frac{\sum_n n^2 E[B_n^2]}{T^2 S_2}$$
$$\sigma_{MC} = \frac{\sigma_B}{T \sqrt{S_2}}$$

Comme  $S_2 = \sum_n n^2 > N^2$ , on a  $\sqrt{S_2} > N$  donc  $\sigma_{MC} < \sigma_{emp} = \frac{\sigma_B}{NT}$ .  
Notre estimateur est meilleur que l'estimateur empirique.

### TD1.4 Estimateur du maximum de vraisemblance

1. L'estimateur du maximum de vraisemblance de  $V$  est donné par

$$\hat{v}_{MV} = \arg_V \max f_{\mathbf{Y}}(\mathbf{y})$$

Remarque : dans le cas où  $V$  est incertain,  $\arg_v \max f_{\mathbf{Y}/V=v}(\mathbf{y})$ .

$Y$  suit une loi gaussienne donc :

$$\hat{v}_{MV} = \arg_V \max f_{\mathbf{Y}}(\mathbf{y}) = \arg_V \min \sum_n (y_n - nTV)^2 = \arg \min J_{MC}(V)$$

2. Identique à la partie précédente car  $\hat{V}_{MV} = \hat{V}_{MC}$ .

### TD1.5 Estimateur du maximum a posteriori

- $V$  suit une loi gaussienne  $N(V_0, \sigma_V^2)$
- les VA  $B_n$  et  $V$  sont indépendantes 2 à 2

On a 2 types d'informations :

- celle qui vient des mesures  $y_n$
- celle qui vient de l'a priori  $V$

1. Dans le cas où  $V = v$  ( $v$  est certain), on ne change pas pour autant le comportement de  $B_1, \dots, B_n$ , donc de  $Y_1 \dots Y_n$  :

$$f_{\mathbf{Y}/V=v}(\mathbf{y}) = \frac{1}{(2\pi)^{N/2} \sigma_B^N} \exp\left(-\frac{1}{2} \frac{\sum_n (y_n - nTv)^2}{\sigma_B^2}\right)$$

2. On utilise la règle de Bayes :

$$f_{V/\mathbf{Y}=\mathbf{y}}(v) = \frac{f_{\mathbf{Y}/V=v}(\mathbf{y}) f_V(v)}{f_{\mathbf{Y}}(\mathbf{y})}$$

$f_{\mathbf{Y}}(\mathbf{y})$  ne dépend pas de  $v$  car on peut la calculer selon  $f_{\mathbf{Y}}(\mathbf{y}) = \int_{\mathbb{R}} f_{\mathbf{Y},V}(\mathbf{y}, v) dv$ .

3. L'estimateur du maximum a posteriori de  $V$  est donné par :

$$\hat{v}_{MAP} = \arg_v \max f_{V/\mathbf{Y}=\mathbf{y}}(v)$$

Or

$$f_{V/\mathbf{Y}=\mathbf{y}}(v) = cste \times \exp\left(-\frac{1}{2} \left( \frac{\sum_n (y_n - nvT)^2}{\sigma_B^2} + \frac{(v - V_0)^2}{\sigma_V^2} \right)\right)$$

On pose  $J_{MAP} = \frac{\sum_n (y_n - nvT)^2}{\sigma_B^2} + \frac{(v - V_0)^2}{\sigma_V^2}$  et on a alors  $\hat{v}_{MAP} = \arg_v \min J_{MAP}(v)$ .

CNS de maximisation :

$$\begin{aligned} \frac{dJ_{MAP}}{dV}|_{V=\hat{v}_{MAP}} = 0 &\Leftrightarrow -2T \frac{\sum_n (y_n - nvT)n}{\sigma_B^2} + 2 \frac{(v - V_0)}{\sigma_V^2} = 0 \\ &\Leftrightarrow \hat{v}_{MAP} = \frac{\frac{T \sum_n n y_n}{\sigma_B^2} + \frac{V_0}{\sigma_V^2}}{\frac{T^2 \sum_n n^2}{\sigma_B^2} + \frac{1}{\sigma_V^2}} \\ &\Leftrightarrow \hat{v}_{MAP} = \frac{\frac{\hat{v}_{MV}}{\sigma_{MV}^2} + \frac{V_0}{\sigma_V^2}}{\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}} \end{aligned}$$

Donc

$$\hat{V}_{MAP} = \frac{\frac{\hat{V}_{MV}}{\sigma_{MV}^2} + \frac{V_0}{\sigma_V^2}}{\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}}$$

C'est un barycentre entre les mesures représentées par  $\hat{v}_{MV}$  et l'a priori  $V_0$ .

- Si  $\sigma_V$  "petit", alors  $\hat{V}_{MAP} \approx V_0$  : beaucoup d'a priori donc on n'a pas exploité les mesures.
- Si  $\sigma_V$  "grand", alors  $\hat{V}_{MAP} \approx \hat{V}_{MV}$  : l'a priori est tellement pourri qu'on n'en tient pas compte.

4. On forme l'erreur d'estimation

$$\tilde{V}_{MAP} = \hat{V}_{MAP} - V$$

- Biais ?

$$E[\tilde{V}_{MAP}] = E[\hat{V}_{MAP}] - E[V] = 0$$

- Variance de l'erreur d'estimation : puissance de l'erreur dans le cas non biaisé.

$$\begin{aligned} \sigma_{MAP}^2 &= E[(\tilde{V}_{MAP} - E[\tilde{V}_{MAP}])^2] \\ &= E[(\hat{V}_{MAP} - V)^2] \\ &= E\left[\left(\frac{\frac{\hat{V}_{MV} - V}{\sigma_{MV}^2} + \frac{V_0 - V}{\sigma_V^2}}{\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}}\right)^2\right] \\ &= \frac{1}{\left(\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}\right)^2} E\left[\left(\frac{\hat{V}_{MV} - V}{\sigma_{MV}^2} + \frac{V_0 - V}{\sigma_V^2}\right)^2\right] \\ &= \frac{1}{\left(\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}\right)^2} \left(\frac{E[(\hat{V}_{MV} - V)^2]}{\sigma_{MV}^4} + \frac{E[(V_0 - V)^2]}{\sigma_V^4}\right) \\ &= \frac{1}{\left(\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}\right)^2} \left(\frac{\sigma_{MV}^2}{\sigma_{MV}^4} + \frac{\sigma_V^2}{\sigma_V^4}\right) \\ \sigma_{MAP}^2 &= \left(\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_V^2}\right)^{-1} \end{aligned}$$

On a donc  $\sigma_{emp} > \sigma_{MV} > \sigma_{MAP}$ .