



M1 E3A - VOIE ANDRÉ AMPÈRE

UE451


## TRAITEMENT DU SIGNAL ET DE L'IMAGE

Un cours de:  
CÉCILE DURIEU

Rédigé par:  
PIERRE-ANTOINE COMBY

école  
normale  
supérieure  
paris—saclay

université  
PARIS-SACLAY



# Introduction

Les signaux déterministe sont utilisé pour les test ou les commandes . Ils sont cependant insuffisant pour décrire l'ensemble des phénomènes qui peuvent être aléatoire ou stochastique. Il est donc nécessaire d'introduire des "signaux aléatoires" (SA).

**Exemple:** *Lot de resistances "identiques"* On considère un lot de résistance de même valeur indiquée par le code couleur, et de même précision. Elles ont en réalité toutes des valeurs différentes  $R_i$ . on note  $s_i(t)$  , la tension au borne de  $R_i$ .

On a  $s_i(t) = 0$  mais avec  $A \gg 1$  on obtient  $A.s_i(t) \neq 0$ .

Alors :  $s_i(t) = 0$  mais il existe une fluctuation de la tension due au bruit thermique.

On note alors :

$$s_i(t) = s(t, i) = s(t, \omega)$$

C'est une réalisation particulière du SA, appelé par la suite trajectoire.

Dans le cas général on parle de fonction aléatoire  $F(\theta, \omega)$  ,où  $\theta$  est un paramètre certain (comme le temps par exemple).

**Remarque:** Un signal aléatoire n'est caractérisé qu'en moyenne.

- moyenne à  $\omega$  donné :  $s(t, \omega_0) = s_0(t)$  : **moyenne temporelle**
- moyenne à  $t$  donné :  $s(t_0, \omega) = s_0(\omega)$  : **moyenne statistique**.

On dit aussi que  $S(t, \omega) = S_t(\omega)$  est une famille de variable aléatoire indexé par le temps, qui décrit l'aspect incertain à chaque instant.




FIGURE 1 – Représentation des trajectoires d'un signal aléatoire

# Table des matières

<b>1</b>	<b>Rappel d'élément de probabilité et de VA</b>	<b>4</b>
1	Probabilités . . . . .	4
1.1	Évènement . . . . .	4
1.2	Probabilités . . . . .	4
1.3	Probabilités conditionnelles . . . . .	5
1.4	Indépendance . . . . .	5
2	Variable aléatoire réelle et scalaire . . . . .	6
2.1	Généralité et exemple . . . . .	6
2.2	Fonction de répartition . . . . .	6
2.3	Densité de probabilité . . . . .	7
2.4	Changement de VA . . . . .	8
2.5	Expérance, moment et fonction caractéristique . . . . .	8
2.6	Fonction caractéristique . . . . .	9
3	Couple de variable aléatoire réelles . . . . .	10
3.1	Généralité . . . . .	10
3.2	Fonction de répartition . . . . .	10
3.3	Densité de probabilité . . . . .	11
3.4	Indépendance . . . . .	11
3.5	Changement de VA . . . . .	12
3.6	Espérance et moments-fonction caractéristique . . . . .	12
3.7	Espérance de loi conditionnelle . . . . .	14
4	Variable aléatoire vectorielle et réelles . . . . .	14
4.1	Définition . . . . .	14
4.2	Fonction de répartition . . . . .	15
4.3	Densité de Probabilité . . . . .	15
4.4	Indépendance . . . . .	16
4.5	Changement de variable aléatoire . . . . .	16
4.6	Espérance, moments et fonction caractéristique . . . . .	16
4.7	Va Gaussienne et réelle . . . . .	17
5	Extension aux VA complexes . . . . .	17
<b>2</b>	<b>Signaux Aléatoire</b>	<b>19</b>
1	Stationnarité et ergodicité . . . . .	19
1.1	Moyenne temporelle . . . . .	19
1.2	Ergodicité . . . . .	20
1.3	Moyenne statistique . . . . .	21
1.4	Stationnarité . . . . .	21
1.5	Stationnarité et ergodicité . . . . .	21

2	Corrélation et densité spectrale de puissance . . . . .	22
3	Periodogramme . . . . .	23
4	Signaux aléatoire particulier . . . . .	23
4.1	SA indépendants . . . . .	23
4.2	SA décorrelés . . . . .	23
<b>3</b>	<b>Filtrage des Signaux Aléatoires</b>	<b>24</b>
1	Formule des moments et des interférences . . . . .	24
2	Application . . . . .	25
2.1	Blanchiment d'un signal . . . . .	25
2.2	Identification d'un filtre linéaire . . . . .	25
2.3	Signaux ARMA . . . . .	25
2.4	Signaux AR : illustration . . . . .	26
2.5	Filtre Adapté (FA) . . . . .	26
<b>4</b>	<b>Estimation</b>	<b>27</b>
1	Introduction . . . . .	27
1.1	Problématique . . . . .	27
1.2	Performance-Qualité d'une estimation . . . . .	29
1.3	Caractérisation des estimateurs . . . . .	29
2	Théorie classique de l'estimation . . . . .	30
2.1	Estimateur des moindres carrés . . . . .	30
2.2	Estimateur du maximum de vraisemblance . . . . .	32
3	Théorie générale de l'estimation . . . . .	32
3.1	Estimateur linéaire en moyenne quadratique (ELMQ) . . . . .	32
3.2	Estimateur Bayésiens . . . . .	34
4	Conclusion . . . . .	38

# Chapitre 1

## Rappel d'élément de probabilité et de VA

### 1 Probabilités

#### 1.1 Évènement

- La réalisation d'une expérience aléatoire (on ne peut pas prédire avec certitude le résultat) est un *évènement*  $\omega$ , singleton de  $\Omega$  ensembles de tous les évènements.

**Exemple:** *jet de dé* aux évènements "Tirer 1, ... ,6 " on associe  $\Omega = \omega_1, \dots, \omega_6$

- $\mathcal{E}$  est une tribu (ou  $\sigma$ -algèbre) de  $\Omega$ , tel que :
  - $\Omega \in \mathcal{E}$
  - $\mathcal{E}$  est stable par union, intersection et complémentarité.

#### 1.2 Probabilités

##### Définition

On appelle probabilité :

$$P : \begin{cases} \mathcal{E} & \rightarrow [0, 1] \\ E & \mapsto P(E) \end{cases}$$

tel que:

- $P(\Omega) = 1$
- $\forall E_i, i \in \mathbb{I}$ , des év disjoint 2 à 2,  $\implies P\left(\bigcup_{i \in \mathbb{I}} E_i\right) = \sum_{\mathbb{I}} P(E_i)$

### Proposition

- $P(\bar{E}) = 1 - P(E)$
- $(P(\emptyset) = 0)$
- $A \subset B \implies P(A) \leq P(B)$
- $P(A + B) = P(A) + P(B) - P(A \cap B)$

## 1.3 Probabilités conditionnelles

### Définition

Soit  $A$  et  $B$  deux événements. On appelle *probabilité conditionnelle* la probabilité de  $A$  sachant que  $B$  est réalisé :

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

### Proposition (Formule de Bayès)

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

## 1.4 Indépendance

### Définition

Deux événements  $A$  et  $B$  sont dits *indépendants* si et seulement si le fait que  $A$  est réalisé n'apporte pas d'information sur la réalisation de  $B$

$$\begin{aligned} P(A|B) &= P(A) \\ \iff P(B|A) &= P(B) \\ \iff P(A \cap B) &= P(A).P(B) \end{aligned}$$

### Définition

Des événements  $(E_i)_{i \in \mathbb{I}}$  sont dits mutuellement indépendants (ou encore indépendants dans leur ensemble), si et seulement si :

$$P\left(\bigcap_{i \in \mathbb{I}} E_i\right) = \prod_{i \in \mathbb{I}} P(E_i)$$

**Proposition**

L'indépendance dans son ensemble implique l'indépendance deux à deux.  
La réciproque n'est pas forcément vraie.

## 2 Variable aléatoire réelle et scalaire

On se place dans un espace probabilisé  $\Omega$  donné.

### 2.1 Généralité et exemple

**Définition**

On appelle *Variable aléatoire* (VA) :

$$X : \begin{cases} \Omega \rightarrow \mathbb{R} \\ \omega \mapsto X(\omega) = x \end{cases}$$

**Exemple:**

- Dé à  $n$  faces (discret)
- distance d'une flèche au centre de la cible.

**Proposition**

Pour des variables aléatoires continues,

$$P(X = x) = 0, \forall x \in \mathbb{R}$$

car  $x$  est un point de mesure nulle.

### 2.2 Fonction de répartition

**Définition**

On appelle fonction de répartition:

$$\begin{aligned} F_X(x) &= P(X \leq x) = P(X \in ]-\infty, x]) \\ &= P(\{\omega \in \Omega \mid X(\omega) \leq x\}) \end{aligned}$$

### Proposition

- $0 \leq F_X(x) \leq 1$
- $P(a \leq X \leq b) = F_X(b) - F_X(a)$
- $F_x$  est une fonction :
  - non décroissante
  - continue presque partout

Une variable aléatoire est complètement caractérisée par sa f.d.r

**Remarque:** Dans le cas d'une VAD,  $F_X$  est en marche d'escalier.

## 2.3 Densité de probabilité

### Définition

On appelle *densité de probabilité* la fonction :

$$f_X(x) \stackrel{\mathcal{D}}{=} \frac{dF_X(x)}{dx}$$

Avec la dérivée généralisée au sens des distributions.

### Proposition

- Les fonction de densité de probabilité et de répartition sont équivalentes pour décrire une variable aléatoire.
- $f_X(x) \geq 0$
- $\int_{-\infty}^{+\infty} f_X(x) dx = 1$
- $\int_{-\infty}^x f_X(\alpha) d\alpha = F_X(x)$

**Remarque:** Pour les variables aléatoires discrètes, la ddp est une suite d'impulsion de Dirac :

$$f_X(x) = \sum_{i \in \mathbb{I}} p_i \delta(x - x_i)$$

**Exemple:**

- VAC uniforme sur  $[a, b]$  :

$$f_X(x) = \frac{1}{b-a} \mathbb{1}_{[a,b]}$$

- VAC gaussienne :

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \frac{(x - m_x)^2}{\sigma_x^2}\right)$$



## 2.4 Changement de VA

### Proposition

Soit  $g : \begin{cases} \mathbb{R} \rightarrow \mathbb{R} \\ X \mapsto g(X) = Y \end{cases}$  une fonction homéomorphique<sup>1</sup>

Alors :

$$f_Y(y) = f_X(x) \left| \frac{dx}{dy} \right| = f_X(x) \frac{1}{\left| \frac{dy}{dx} \right|}$$

Dans le cas où  $g$  n'est pas bijective :

$$f_Y(y) = \sum_{x_i | g(x_i) = y} f_X(x) \left| \frac{dx}{dy} \right|_{x=x_i}$$

## 2.5 Espérance, moment et fonction caractéristique

### Définition

pour  $g: \mathbb{R} \rightarrow \mathbb{C}^p$  On appelle *espérance* d'une variable aléatoire la grandeur:

$$E(g(X)) = \int_{\mathbb{R}} g(x) f_X(x) dx$$

Dans le cas discret on a:

$$E(g(X)) = \sum_{\mathbb{I}} g(x_i) P(X = x_i)$$

### Proposition

L'espérance est linéaire (sous réserve d'existence) :

- $E[c] = c$
- $E[cg(x)] = cE[g(x)]$
- $E[g(x) + h(x)] = E[g(x)] + E[h(y)]$

**Remarque:** On note aussi  $E[X] = m_X = m$  “moyenne de la variable aléatoire”. Si  $m = 0$  on dit que la VA est centrée.

1. continue, bijective continue

**Définition**

On appelle *moment d'ordre k*:

$$m_k = E[X^k]$$

Le *moment centré d'ordre k* :

$$m_k = E[(X - m_X)^k]$$

Le moment  $\mu_2$  est aussi appelé la *variance*

**Remarque:** on note  $\sigma_x = \sqrt{v_x}$  l'écart type de X. Il mesure la dispersion autour de  $m_x$ . On définit la variable centrée réduite associée à X :

$$X_r = \frac{X - m_X}{\sigma_X}$$

## 2.6 Fonction caractéristique

**Définition**

On appelle fonction caractéristique:

$$\phi_X(u) = E[\exp(juX)] = \int_{-\infty}^{+\infty}$$

**Proposition**

- $\phi_X(u)$  existe toujours  $|\phi_X(u)| \leq \phi_X(0) = 1$
- Symétrie hermitienne
- $\phi_X(u)$  est continue même pour des VA discrètes
- On appelle 2ème fonction de répartition  $\Psi_X(u) = \ln(\phi_X(u))$
- 

$$m_k = (-j)^k \left. \frac{d^k \phi_X(u)}{du^k} \right|_{u=0}$$

### 3 Couple de variable aléatoire réelles

#### 3.1 Généralité

##### Définition

Un couple de variable aléatoire est défini comme:

$$Z \begin{cases} \Omega \rightarrow \mathbb{R}^2 \\ \omega \mapsto Z(\omega) = \begin{bmatrix} X(\omega) \\ Y(\omega) \end{bmatrix} \end{cases}$$

On définit également:

$$Z^{-1} : \mathcal{D} \mapsto Z^{-1}(\mathcal{D}) = E_D \subset \mathcal{E}$$

#### 3.2 Fonction de répartition

##### Définition

- fonction de répartition conjointe:

$$\begin{aligned} P(X < x; Y < y) &= F_{XY}(x, y) \\ &= P((x, y) \in \mathcal{D}) \\ &= F_Z(z) \end{aligned}$$

- fonction de répartition marginale

$$\begin{aligned} F_X(x) &= P(X < x) = F_{XY}(x, +\infty) \\ &= P((x, y) \in \mathcal{D}_X) \end{aligned}$$




FIGURE 1.1 – Représentation des domaines d'existence possible pour  $X, Y$

### 3.3 Densité de probabilité

#### Définition

on définit la densité de probabilité conjointe:

$$f_{XY} = \frac{\partial^2 F_{XY}(x, y)}{\partial x \partial y}$$

#### Proposition

densité de probabilité conjointe et fonction de répartition sont reliées :

$$\int_{-\infty}^{x^-} \int_{-\infty}^{y^-} f_{XY}(\alpha, \beta) d\alpha d\beta = F_{XY}(x, y)$$

et :

$$\int_{-\infty}^x \int_{\mathbb{R}} f_{XY}(\alpha, \beta) d\beta = F_{XY}(x, \infty) = F_X(x)$$

#### Définition

À partir de la fonction de répartition marginale on peut définir la loi marginale de  $X$  :

$$f_X(x) = \frac{dF_X(x)}{dx} = \int_{\mathbb{R}} f_{XY}(x, y) dy$$

Et alors la loi conditionnelle de  $X$  sachant  $Y$ :

$$f_{X|Y}(x) = \frac{f_{XY}(x, y)}{f_Y(y)}$$

### 3.4 Indépendance

#### Définition

On dit que  $X$  et  $Y$  sont indépendants:

$$\iff F_{XY}(x, y) = F_X(x)F_Y(y)$$

$$\iff f_{XY}(x, y) = f_X(x)f_Y(y)$$

### 3.5 Changement de VA

#### Proposition

On considère :

Alors : 
$$g \begin{cases} \mathbb{R}^2 \rightarrow \mathbb{R}^2 \\ Z = (X, Y) \mapsto W = (U, V) = g(X, Y) \\ f_W(w) = f_Z(z)|J| \end{cases}$$

où :

$$J = \begin{pmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{pmatrix}$$

**Remarque:** Il est parfois plus simple de calculer :

$$|K| = \begin{vmatrix} \frac{\partial x}{\partial u} & \frac{\partial x}{\partial v} \\ \frac{\partial y}{\partial u} & \frac{\partial y}{\partial v} \end{vmatrix}$$

Au quel cas on a :  $f_W(w) = f_Z(z) \frac{1}{|K|}$

### 3.6 Espérance et moments-fonction caractéristique

Dans la suite on considère la fonction suivante :

$$g : \begin{cases} \mathbb{R}^2 \rightarrow \mathbb{C}^p \\ Z = (X, Y) \mapsto g(Z) = \begin{bmatrix} g_1(X, Y) \\ \vdots \\ g_p(X, Y) \end{bmatrix} \end{cases}$$

#### Théorème (Théorème de transfert)

On a :

$$E[g(z)] = \iint_{\mathbb{R}^2} g(X, Y) f_{X,Y}(x, y) dx dy$$

#### Proposition

Dans le cas de VA indépendante et pour  $g$  séparable on a :  $g(X, Y) = g_X(X)g_Y(Y)$  et alors :

$$E[g(X, Y)] = E[g_X(X)]E[g_Y(Y)]$$

**Définition**

On peut également définir les moments d'un couple de VA:

- Moment d'ordre 1

$$E[Z] = m_Z = \begin{bmatrix} m_X \\ m_Y \end{bmatrix}$$

- Moment d'ordre 2 (Matrice de corrélation)

$$E[ZZ^T] = E \left[ \begin{bmatrix} X^2 & XY \\ XY & Y^2 \end{bmatrix} \right] = \begin{bmatrix} E[X^2] & E[XY] \\ E[XY] & E[Y^2] \end{bmatrix} = C_{ZZ}$$

**Remarque:**  $C_{ZZ}$  est symétrique positive :  $C_{ZZ} \in S_n^+(\mathbb{R})$

**Définition**

On appelle matrice de covaraince la matrice de corrélation des variables centrées:

$$\Sigma_{ZZ} = E[(X - m_x)(Y - m_y)^T] = \begin{bmatrix} \sigma_x^2 & \rho_{XY}\sigma_X\sigma_Y \\ \rho_{XY}\sigma_X\sigma_Y & \sigma_Y^2 \end{bmatrix}$$

où  $\rho_{XY} = \frac{E[(X-m_x)(Y-m_y)^T]}{\sigma_x\sigma_y} = E[X_r Y_r]$  est le *coefficient de corrélation*

**Proposition**

- $\Sigma_{ZZ} \in S_n^+$
- $\rho_{XY} < 1$
- $\rho_{XY} = 1$  ssi  $\exists a, b, c \neq 0, aX + bY + c = 0$ . Les variables sont alignées.
- Si  $\rho_{XY} = 0$  on dit que les variables sont décoréllées

**Théorème**

L'indépendance de 2 variables aléatoires implique leur non corrélation.  
La réciproque n'est vraie que dans le cas gaussien.

### 3.7 Espérance de loi conditionnelle

#### Définition

On note

$$E[X|Y = y] = \int_{\mathbb{R}} x f_{X|Y=y}(x) dx = m_X(y)$$

*l'espérance conditionnelle* de la VA  $X$  sachant  $Y = y$

#### Proposition

On a :

$$E[m_X(y)] = E[X]$$

**Démonstration :** Directement :

$$\begin{aligned} E[m_X(y)] &= \int_{\mathbb{R}} m_X(y) f(y) dy \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} x f_{XY}(x, y) dx dy \\ &= \int_{\mathbb{R}^2} x f_{XY}(x, y) dx dy \\ &= E[X] \end{aligned}$$

■

## 4 Variable aléatoire vectorielle et réelles

### 4.1 Définition

#### Définition

On généralise la notion de variable aléatoire et de couple de variable aléatoire :

$$X : \begin{cases} \Omega \rightarrow \mathbb{R}^n \\ \omega \mapsto X(\omega) = \begin{bmatrix} X_1 \\ \vdots \\ X_n \end{bmatrix} \end{cases}$$

## 4.2 Fonction de répartition

### Définition

- Fonction de répartition conjointe: (toutes les composantes jouent le même rôle)

$$F_{X_1 \dots X_n}(x_1 \dots x_n) = P\left(\bigcap_{i=1}^n X_i < x_i\right)$$

- Fonction de répartition marginale de  $X_i$ :

$$F_{X_i} = P(X_i < x_i) = P\left(X_i < x_i; \bigcap_{j \neq i} X_j < +\infty\right)$$

Les propriétés démontrées dans le cas 2 se généralise au cas vectoriel.

## 4.3 Densité de Probabilité

### Définition

On défini la densité de probabilité conjointe:

$$f_{\mathbf{X}}(\mathbf{x}) = \frac{\partial^n}{\partial \mathbf{x}} F_{\mathbf{X}}(\mathbf{x})$$

Et alors :

$$P(X \in \mathcal{D}) = \int_{\mathcal{D}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x} = \int \int \dots \int_{\mathcal{D}} f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

### Définition

On généralise de même les notions de ddp marginale et conditionnelle:

- ddp marginale:

$$f_{X_i}(x_i) = \frac{d^n F_{x_i}(x_i)}{dx_i} = \int_{\mathbb{R}^{n-1}} f_{\mathbf{X}}(\mathbf{x}) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n$$

- ddp conditionnelles: On considère  $Y$  et  $Z$  de VA vectorielles:

$$f_{\mathbf{Y}|\mathbf{Z}=\mathbf{z}}(\mathbf{y}) = \frac{f_{\mathbf{YZ}}(\mathbf{y}, \mathbf{z})}{f_{\mathbf{Z}}(\mathbf{z})}$$



## 4.4 Indépendance

### Théorème

On donne une CNS d'indépendance dans leur ensemble des VA  $X_i$  :

L'indépendance dans leur ensemble implique l'indépendance 2 à 2.

$$f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i) \iff f_{\mathbf{X}}(\mathbf{x}) = \prod_{i=1}^n f_{X_i}(x_i)$$

## 4.5 Changement de variable aléatoire

### Proposition

Pour  $g \begin{cases} \mathbb{R}^n \rightarrow \mathbb{R}^n \\ \mathbf{X} \mapsto g(\mathbf{X}) = \mathbf{Y} \end{cases}$  On peut définir le changement de variable :

$$f_{\mathbf{Y}(\mathbf{y})} = f_{\mathbf{X}(\mathbf{x})} |\mathbf{J}| = f_{\mathbf{X}}(\mathbf{x}) \frac{1}{|\mathbf{K}|}$$

où :  $\mathbf{J} = \frac{\partial \mathbf{x}}{\partial \mathbf{y}^T} = x_{i,j}$  et  $\mathbf{K} = \frac{\partial \mathbf{y}}{\partial \mathbf{x}^T} = y_{j,i}$

## 4.6 Espérance, moments et fonction caractéristique

### Théorème (*Théorème de transfert*)

$$E[g(\mathbf{X})] = \int_{\mathbb{R}^n} g(\mathbf{X}) f_{\mathbf{X}}(\mathbf{x}) d\mathbf{x}$$

### Définition

- Moment d'ordre 1:

$$\mathbf{m}_{\mathbf{X}} = E[\mathbf{X}]$$

- Moment d'ordre 2: (matrice de corrélation)

$$\mathbf{C}_{\mathbf{X}\mathbf{X}} = E[\mathbf{X}\mathbf{X}^T] \geq 0$$

- Moment centrée d'ordre 2: (matrice de covariance)

$$\mathbf{\Sigma}_{\mathbf{X}\mathbf{X}} = E[(\mathbf{X} - \mathbf{m}_{\mathbf{X}})(\mathbf{X} - \mathbf{m}_{\mathbf{X}})^T]$$

- Fonction caractéristique:

$$\phi_{\mathbf{X}}(\mathbf{u}) = E[e^{j\mathbf{u}^T \mathbf{X}}]$$

## 4.7 Va Gaussienne et réelle

### Définition

On dit que  $X = \mathbf{X}_1 : \mathbf{X}_n$  est une VA gaussienne:

- $\iff X_i$  sont gaussiens et indépendants dans leur ensembles
- $\iff \sum_{i=1}^n \alpha_i X_i$  est une gaussienne.

### Proposition

- $\mathbf{X} \sim \mathcal{N} \implies X_i \sim \mathcal{N}$ . La réciproque n'est pas vraie (cf ex 9/10 p 14 du fascicule)
- $\mathbf{X} \sim \mathcal{N} \implies$  loi conditionnelle gaussienne.
- $X_i \sim \mathcal{N}$  et indépendantes dans leur ensemble  $\implies \mathbf{X} \sim \mathcal{N}$ .
- $\mathbf{X} \sim \mathcal{N}$  et  $X_i$  indépendants 2à2  $\implies$  indépendant dans leur ensemble.
- $\mathbf{X} \sim \mathcal{N} \implies \mathbf{Y} = \mathbf{A}\mathbf{X} + \mathbf{B} \sim \mathcal{N}$

## 5 Extension aux VA complexes

### Définition

On généralise *encore*:

$$\mathbf{Z} \begin{cases} \Omega \rightarrow \mathbb{C}^p \\ \omega \mapsto \mathbf{Z}(\omega) = \mathbf{X} + j\mathbf{Y} \end{cases}$$

**Notation** :  $\mathbf{Z}^\dagger = (\mathbf{Z}^*)^T$  transposé conjugué.

**Proposition**

---

- Fonction de répartition :

$$f_{\mathbf{Z}}(\mathbf{z}) = P(\mathbf{X} < \mathbf{x}; \mathbf{Y} < \mathbf{y})$$

- Matrice de corrélation :

$$\mathbf{C}_{\mathbf{ZZ}} = E[\mathbf{ZZ}^\dagger]$$

- Matrice de covariance :

$$\mathbf{\Sigma}_{\mathbf{ZZ}} = E[(\mathbf{Z} - \mathbf{m}_{\mathbf{z}})(\mathbf{Z} - \mathbf{m}_{\mathbf{z}})^\dagger]$$

- Fonction caractéristique :

$$\phi_{\mathbf{Z}}(\mathbf{u}) = E[e^{j\mathbf{u}^\dagger \mathbf{Z}}]$$

- La linéarité de l'espérance donne également :

$$E[g(\mathbf{Z})^*] = E[g(\mathbf{Z})]^*$$

# Chapitre 2

## Signaux Aléatoire

### 1 Stationnarité et ergodicité

#### Définition

Soit  $(\Omega, \mathcal{E}, P)$  un espace probabilisé. Une famille/suite de VA indexé par le temps est un *signal aléatoire*  $\in \mathbb{C}^n$  noté :  $X_t(\omega) \forall t \in \mathbb{R}$  (ou  $X_n(\omega) \forall n \in \mathbb{Z}$ )

En pratique on s'intéresse à des signaux de dimension 1.

**Rappel :** on appelle trajectoire la réalisation / acquisition d'un signal. il existe deux types de moyenne possible :

- temporelle, idem que celle des signaux déterministes
- Statistique, idem que pour les VA.

**Exemple:** Soit le SA suivant :  $X(t, \omega) = A \sin(2\pi f_0 t)$  où  $A$  est une variable aléatoire, (ici qui suit une loi uniforme). Alors une réalisation de ce SA est  $x(t) = a \sin(2\pi f_0 t)$ .

- $\overline{x(t, \omega)} = 0 = m_x$  et  $\overline{x^2(t, \omega)} = \frac{a^2}{2}$
- $E[X(t, \omega)] = \sin(2\pi f_0 t) E[A] = m_X(t)$ .

#### 1.1 Moyenne temporelle

On rappelle les différentes expressions des 1er et 2nd ordre (si il existe) de trajectoire particulière.

**Définition**

Les moments d'ordre 1 temporel sont des *moyennes temporelle*:

- Temps continu

$$\overline{x(t, \omega)} = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T x(t, \omega) dt = m_x(\omega)$$

- Temps discret

$$\overline{x[n, \omega]} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N x[n, \omega] = m_x(\omega)$$

**Définition**

Les moments d'ordre 2 croisés définissent la fonction d'intercorrélation temporelle (( $\omega$  est fixé )

- Temps continu:

$$\overline{x(t, \omega) \cdot y^*(t - \tau, \omega)} = \lim_{T \rightarrow \infty} \frac{1}{2T} \int_{-T}^T x(t, \omega) y^*(t - \tau, \omega) dt = C_{xy}^p(\tau, \omega)$$

- Temps discret:

$$\overline{x[n, \omega] y^*[n - k, \omega]} = \lim_{N \rightarrow \infty} \frac{1}{2N+1} \sum_{n=-N}^N x[n, \omega] y^*[n - k, \omega]$$

**Remarque:** On dit également que les Les moments temporels dépendent de la trajectoire.  
Si  $y = x$  on parle d'autocorrélation. De plus  $C_{xx}^p(0)$  est la *puissance* de  $x$ .

## 1.2 Ergodicité

**Définition**

- Un processus est *ergodique au sens stricte* si et seulement si toutes les moyennes temporelles sont indépendantes de la trajectoire considérée.
- Un processus est ergodique à l'ordre  $n$  si et seulement si tous les moments jusqu'à l'ordre de  $n$  sont indépendant de la trajectoire considéré. Les moments temporel d'un signal ergodique ne sont pas des variables aléatoires.

**Remarque:** Souvent  $n = 2$  Pour 2 SA on parle d'ergodicité dans leur ensemble.

### 1.3 Moyenne statistique

On considère les signaux aléatoire à des instants particuliers, fixé.

**Remarque:** En fixant le temps on peut définir les fonctions de répartition et la densité de probabilité d'un signal aléatoire. Alors on peut exprimer les moments statistiques de ses signaux temporels :

**Définition**

On défini la moyenne statistique (moment d'ordre 1):

$$m_X(t) = E[X(t, \omega)] = \int_{\mathbb{R}} x f_X(x, t) dx$$

et la fonction d'intercorrélation statistique (moment d'ordre 2):

$$\gamma_{xy}(t_1, t_2) = E[X(t_1, \omega) y^*(t_2, \omega)] = \iint xy^* f_{x,y,t_1,t_2} dx dy$$

Il en est de meme dans le cas discret.

### 1.4 Stationnarité

**Définition**

- Un processus aléatoire est *stationnaire au sens strict* ssi toutes ses caractéristiques statistiques sont invariantes par tout changement de l'origine des temps.

$$f_X(x, t) = f_X(x, t + \tau) = f_X(x) \quad \forall \tau$$

- Un processus aléatoire est stationnaire au sens large /au second ordre ssi ses moments d'ordre 1 et 2 sont invariants par tout changement d'origine des temps.

$$E[|X(t, \omega)|^2] = E[|X(t', \omega)|^2] < +\infty$$

### 1.5 Stationnarité et ergodicité

**Proposition**

Si un SA est à la fois stationnaire et ergodique les moyennes temporelles et statistiques sont égales.

L'ensemble des processus stochastique, stationnaire, ergodique peut être obtenu à partir d'une seule trajectoire allant de  $-\infty$  à  $+\infty$ .

**Proposition**

Un SASE au second ordre est tel que :

$$m_x = E[X(t)] = \overline{x(t)} = m_x$$

et

$$\gamma_{xx}(\tau) = E[X(t)X^*(t-\tau)] = \overline{x(t)x^*(t-\tau)} = C_{xx}^p(\tau)$$

## 2 Corrélation et densité spectrale de puissance

Ici on s'intéresse la répartition de la puissance d'un SA en fonction de la fréquence (idem que la DSE pour des signaux à énergie finie). On se restreint à des SAS du 2nd ordre.

**Notation** :  $x(t, \omega)$  représente le SA ou une de ses réalisations  
 $X(f)$  représente la TF d'un signal  $x$  sous réserve d'existence.

**Théorème (Wiener-Kintchine)**

$$TF[\gamma_{xx}] = \Gamma_{XX}(f) = \text{dsp de } x(t)$$

**Proposition (Cas du TC)**

$$\Gamma_{xy}(f) = \int_{\mathbb{R}} \gamma_{xy}(\tau) e^{-j2\pi f\tau} d\tau$$

$$\gamma_{xy}(\tau) = \int_{\mathbb{R}} \Gamma_{xy}(f) e^{j2\pi f\tau} df$$

$$\gamma_{xy}(0) = \int_{\mathbb{R}} \Gamma_{xy}(f) df = \text{puissance (statistique)}$$

**Proposition (Cas du TD)**

$$\Gamma_{xy}(f) = \sum \gamma_{xy}[k] e^{-j2\pi fk}$$

$$\gamma_{xy}[\tau] = \int_{-1/2}^{1/2} \Gamma_{xy}(f) e^{j2\pi f\tau} df$$

$$P_x = \gamma_{xx}[0] = \int_{-1}^1 \Gamma_{xx}(f) df$$

**Exemple:** cf TP1

**Proposition**

- $|\gamma_{xy}(\tau)| \leq \gamma_{xx}(0) = P_x$
- $\gamma_{xx}(-\tau) = \gamma_{xx}(\tau)^* \implies \Gamma_{xx}(f) \in \mathbb{R}$
- $\Gamma_{xx}(f) > 0$

**Remarque:** très souvent on a  $\gamma_{xx}(\tau) \xrightarrow[+\infty]{|} m_x|^2$ , ce qui signifie qu'on a pas d'effet "mémoire" à l'infini. Si  $m_x \neq 0$  la DSP comporte une raie à l'origine de valeur  $m_x$ .

### 3 Periodogramme

### 4 Signaux aléatoire particulier

#### 4.1 SA indépendants

#### 4.2 SA décorrélés



# Chapitre 3

## Filtrage des Signaux Aléatoires

### 1 Formule des moments et des interférences

On considère les filtres :

$$e \longrightarrow \boxed{\mathcal{FL}} \longrightarrow s$$

On s'intéresse aux filtres linéaires :

#### Définition

- Un filtre linéaire conserve la linéarité des systèmes auxquels il est appliqué.
- Il est temps-invariant.
- et stationnaire.

On peut caractériser un filtre linéaire par :

- sa réponse impulsionnelle  $h$
- sa réponse fréquentielle  $H = TF[h]$
- sa fonction de transfert  $H_{II}$ .

#### Proposition (*Moyenne*)

$$m_s = H(0)m_e$$

Pour deux filtres on a :

$$e_1 \longrightarrow \boxed{\mathcal{H}_1} \longrightarrow s_1$$

$$e_2 \longrightarrow \boxed{\mathcal{H}_2} \longrightarrow s_2$$

**Proposition (Formule des interférences)**

$$\Gamma_{s_1, s_2}(f) = H_1(f) \cdot H_2(f)^* \cdot \Gamma_{e_1, e_2}(f)$$

## 2 Application

### 2.1 Blanchiement d'un signal

Pour générer un bruit blanc  $s(t)$  on veut :

$$\Gamma_0 = |H(f)|^2 \Gamma_{ee}(f) \implies |H(f)|^2 = \frac{\Gamma_0}{\Gamma_{ee}(f)}$$

### 2.2 Identification d'un filtre linéaire

On applique en entrée un bruit blanc tel que  $\Gamma_{ee}(f) = \Gamma_0$ . Alors :

$$\Gamma_{se} = H(f) \Gamma_e(f) \implies H(f) = \frac{\Gamma_{se}(f)}{\Gamma_0} \propto \text{intercorrélacion entrée sortie}$$

### 2.3 Signaux ARMA

On peut utiliser un Filtre Linéaire (FL) pour définir un Signal Aléatoire. (SA). Le SA sera la sortie d'un filtre dynamique (Fonction de transfert rationnel, stable, causal) excité par un bruit blanc.

#### 2.3.1 AR : autoregressif

$$H_{II}(z) = \frac{1}{D(z)} = \frac{1}{1 - \sum_{i=1}^q a_i z^{-i}}$$

Alors on aura en sortie du filtre :

$$s_k = e_k + \sum_{i=1}^q a_i s_{k-i}$$

on parle aussi de filtre « tout pôle »

#### 2.3.2 MA : Moyenne ajustée

$$H_{II}(z) = N(z) = 1 + \sum_{i=1}^q b_i z^{-i}$$

Alors on aura en sortie du filtre :

$$s_k = e_k + \sum_{i=1}^q b_i e_{k-i}$$

### 2.3.3 ARMA

$$H_{II}(z) = \frac{N(z)}{D(z)}$$

On connaît alors  $\Gamma_{ss}$  et le modèle AR. (Équation de Yule Walker, cf TP2)

## 2.4 Signaux AR : illustration

pour une entrée en bruit blanc, les poles proches du cercle unités sont dominant (approche géométrique, joli dessin)

## 2.5 Filtre Adapté (FA)

**Contexte** Problème de transmission numérique (tout ou rien) d'un signal déterministe, connu avec bruit additif.

**Objectif** déterminer le meilleur traitement linéaire pour décider de la présence ou non d'un signal.

Exemple en TD

**Méthode** : Maximiser le RSB à l'instant de décision : avec  $|s_{n_0}^f|^2$  puissance instantanée à l'instant de décision.

$$\frac{|s_{n_0}^f|^2}{E[|b_n^f|^2]}$$

### Proposition (*Application au bruit blanc*)

$$E[|b_n^f|^2] = \int_{-\frac{1}{2}}^{\frac{1}{2}} |H(f)|^2 \Gamma_{bb}(f) df = \Gamma_0 \int_{-\frac{1}{2}}^{\frac{1}{2}} |H(f)|^2 df$$

$$|S_{n_0}^f|^2 = \left| \int_{-\frac{1}{2}}^{\frac{1}{2}} |H(f)|^2 S(f) e^{j2\pi n_0 f} df \right|^2 \leq \int_{-\frac{1}{2}}^{\frac{1}{2}} |H(f)|^2 df \int_{-\frac{1}{2}}^{\frac{1}{2}} |S(f)|^2 df$$

On a égalité si  $H(f) \propto S^*(f) e^{-j2\pi n_0 f} \iff h_n \propto s_{n_0-n}^f$

LA RI du filtre est donc

- un retour temporel
- translaté autour de l'instant de décision (attention à la causalité)
- conjugué.

### Remarque

- Le FA peut être non causal, la RI est alors tronqué et le filtre sous-optimal.
- Le FA est un corrélateur (d'énergie), l'objectif n'est pas de restituer le signal utile mais d'avoir le meilleur RSB à l'instant de décision.

# Chapitre 4

## Estimation

### 1 Introduction

**Objectif** : Présenter quelques éléments de la théorie de l'estimation statistique.

#### 1.1 Problématique

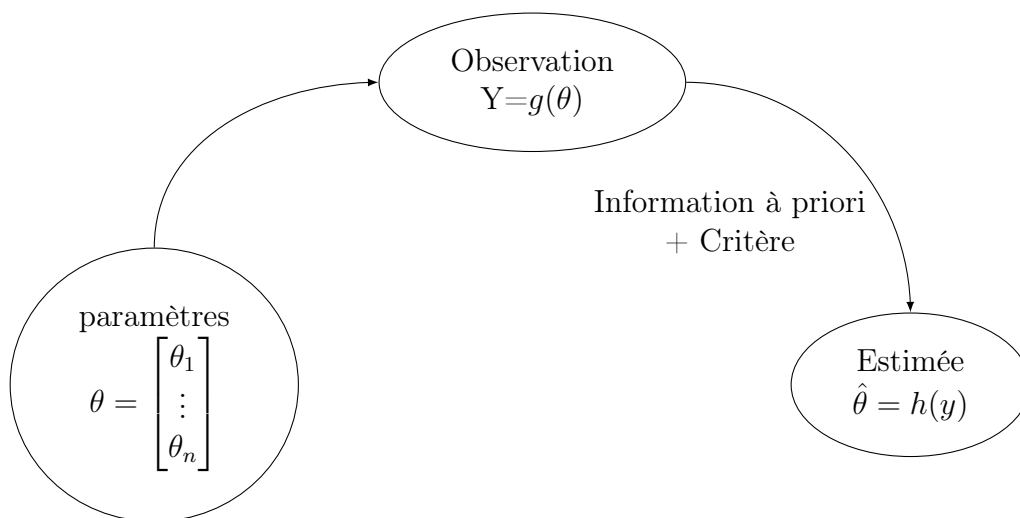


FIGURE 4.1 – Méthode d'estimation classique

Le raisonnement se transpose alors sur la figure suivante :

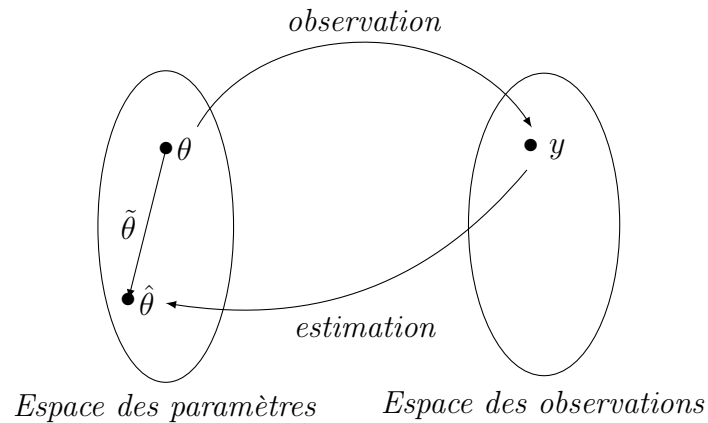


FIGURE 4.2 – Raisonnement en espace algébrique

On définit les index suivants :

**m** nombre d'expérience réalisée (taille de  $y$ )

**n** nombre de paramètres (taille de  $\theta$ )

**Estimateurs statistiques** On observe une réalisation  $y = g(\theta)$  où  $\theta$  est une VA. et on détermine  $\hat{\theta} = h(Y)$  estimée.

### Exemple

**Exemple 1**  $\Theta$  tension constante.

$y(t) = \theta + b(t)$ . soit  $y_i = \theta + b_i$

On définit donc  $Y$  et  $\Theta$  VA et on a  $Y = A\Theta + B \rightarrow$  régression linéaire.

**Exemple 2** filtre RC  $y(t) = (1 - e^{-t/\tau})u(t) + b(t)$ ,  $\Theta = \tau$ . modèle non linéaire, traité en TD.

## 1.2 Performance-Qualité d'une estimation

### Proposition (*Grandeurs utiles*)

- erreur d'estimation

$$\tilde{\theta} = \hat{\theta} - \theta$$

- moment d'ordre 1 :

$$E_{Y|\Theta}[\tilde{\theta}] = E_{Y|\Theta}[\hat{\theta}] - \theta$$

- Biais moyen :

$$E[\tilde{\theta}] = E_{Y|\Theta}[\tilde{\theta}] = E[\hat{\theta}] - \theta$$

- moment d'ordre 2 :

- covariance de l'erreur d'estimation

$$C_{\tilde{\theta}\tilde{\theta}} = E[(\tilde{\theta} - m_{\tilde{\theta}})(.)^T]$$

- Corrélation de l'erreur d'estimation

$$\Gamma_{\tilde{\theta}\tilde{\theta}} = E[\tilde{\theta}\tilde{\theta}^T]$$

- Puissance : (Estimateur Quadratique moyen)

$$P_{\tilde{\theta}} = E[\|\tilde{\theta}\|^2] = \text{tr}(\Gamma_{\tilde{\theta}\tilde{\theta}})$$

## 1.3 Caractérisation des estimateurs

### Définition

- Borne de Cramer Rao: borne minimale du biais de variance (qui dépend de l'estimateur choisi)
- Estimateur non biaisé:  $E[\tilde{\theta}] = 0$
- Estimateur efficace: Borne de Cramer-Rao atteinte.
- Estimateur consistant:  $E[\tilde{\theta}] \xrightarrow{N_{obs} \rightarrow \infty} 0$  et  $V[\tilde{\theta}] \xrightarrow{N_{obs} \rightarrow \infty} 0$
- Estimateur robuste:  
Les performances de l'estimateur ne sont pas trop dégradé si on s'écarte un peu des hypothèses sous laquelle l'estimateur a été établi.
- Complexité de l'estimateur:  
sur l'obtention des connaissances et mise en oeuvre de l'estimateur.

## 2 Théorie classique de l'estimation

### 2.1 Estimateur des moindres carrés

#### Définition

Pour  $Y$  une VA de moyenne  $m_y = m_{Y|\theta}$  on définit le critère :

$$J_{MC} = (Y - m_y)^T M (Y - m_y)$$

Avec  $M$  matrice symétrique définie positive et alors :

$$\hat{\theta}_{MC} = \arg \min_{\theta} J_{MC}(Y, \theta)$$

#### 2.1.1 Condition nécessaire d'existence

Si  $J_{MC}(y, \theta)$  est dérivable et pas de contrainte sur  $\theta$ .

$$\nabla_J(\theta)|_{\hat{\theta}_{MC}} = \frac{\partial J_{MC}}{\partial \theta} = 0 \quad \text{Gradient}$$

Il faut ensuite vérifier que c'est un minimum absolu :

$$\nabla_J^2(\theta) = \frac{\partial^2 J_{MC}}{\partial \theta \partial \theta^T} > 0 \quad \text{Hessien}$$

**Application**  $Y = A\theta + B$ , avec  $B$  une VA. le critère des moindres carrés est alors :

$$J_{MC} = (Y - A\theta - m_B)^T M (Y - A\theta - m_B)$$

On a une forme quadratique positive car  $A^T M A \geq 0$ . (dans le cas  $> 0$  on a une CNS sur ce qui suit)

#### Méthode 1

$$\nabla_J(\theta)|_{\hat{\theta}_{MC}} = 0 = -2A^T M (Y - A\theta - m_B)$$

Donc

$$A^T M A \theta = A^T M (Y - m_B)$$

Soit

$$\hat{\theta}_{MC} = \underbrace{(A^T M A)^{-1} A^T M}_{D} (Y - m_B)$$

On remarque que  $DA = I_n$ .

**Méthode 2** Pour  $A^T M A > 0$ .

$$J_{MC} = \underbrace{(D(Y - m_B) - \Theta)^T A^T M A (D(Y - m_B) - \theta)}_{J_1(Y, \theta)} + \underbrace{(Y - m_B)^T (M - D^T A^T M A D) (Y - m_B)}_{J_2(Y)}$$

Alors  $\nabla J_{MC} = 0 \implies J_1 = 0 \implies D(Y - m_B) = \hat{\theta}_{MC}$

### 2.1.2 Caractéristique de l'estimateur

- Estimateur non biaisé

$$\begin{aligned}\tilde{\theta}_{MC} &= \hat{\Theta} - \theta \\ &= D(Y - m_B) - \theta \\ &= D(B - m_B)\end{aligned}$$

Donc  $E[\hat{\theta}_{MC}] = 0$

- moment d'ordre 2 :

$$C_{\tilde{\theta}\tilde{\theta}} = E[(\tilde{\theta} - m_{\tilde{\theta}})(\cdot)^T] = DE[(B - m_B)(B - m_B)^T]D^T = DC_{BB}D^T$$

- Cas MC ordinaire ( $M = I_n$ )

$$C_{\tilde{\theta}\tilde{\theta}} = (A^T A)^{-1} A^T C_{BB} A (A^T A)^{-1}$$

- Cas MC pondéré ( $M = C_{BB}^{-1}$ )

$$C_{\tilde{\theta}\tilde{\theta}} = (A^T C_{BB}^{-1} A)^{-1}$$

- Cas  $\theta$  scalaire  $Y_i = \theta + B_i$  donc :

$$C_{BB} = \begin{bmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_m^2 \end{bmatrix} \text{ et } A = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}$$

- Cas MCO :  $A^T A = m$

$$\hat{\theta}_{MC} = \frac{\sum (y_i - m_{bi})}{m} \quad \text{et} \quad \sigma_{\tilde{\theta}}^2 = \frac{\sum \sigma_i^2}{m^2}$$

- cas MCP pour  $M = C_{BB}^{-1} = \text{diag}(\sigma_1^{-2}, \dots, \sigma_m^{-2})$

$$A^T C_{BB} A = \sum_{i=1}^m \frac{1}{\sigma_i^2} \quad \text{donc} \quad \hat{\theta}_{MCP} = \frac{1}{\sum \frac{1}{\sigma_i^2}} \sum \frac{Y_i - m B_i}{\sigma_i^2}$$

- $\hat{\theta}_{MCP}$  défini un barycentre



- Pour  $\sigma_i = \sigma$  on a  $M = \sigma I \implies MCO = MCP$
- Comparaison MCO et MCP (avec  $M = C_{BB}$ )

$$\begin{aligned}\sigma_{MCO}^2 &\leq \sigma_{MCP}^2 \\ \frac{1}{\sum \sigma_i^{-2}} &\leq \frac{1}{m^2} \sum \sigma_i^2 \\ m^2 &\leq \frac{1}{\sum \sigma_i^{-2}} \sum \sigma_i^2\end{aligned}$$

## 2.2 Estimateur du maximum de vraisemblance

### Définition

On considère  $f_Y(y)$  ddp de  $y$  paramétrée par  $\theta$ . On a  $f_{Y|\theta}(y) = V(Y, \theta)$ . on pose également  $L(Y, \theta) = \ln(V(Y, \theta))$ . on définit alors:

$$\hat{\theta}_{MV} = \arg \min f_{Y|\theta}(y) = \arg \min L(Y, \theta)$$

GRAPHE

**Exemple** Modèle avec bruit additif gaussien.

### Proposition

Dans le cas d'un bruit Gaussien et pour  $M = C_{BB}^{-1}$

$$\hat{\theta}_{MCP} = \hat{\theta}_{MV}$$

**Remarque** L'estimateur de MV n'est pas nécessairement efficace mais si un estimateur sans biais existe et est efficace c'est celui-ci.

Si  $m \rightarrow \infty$  on montre que le MV est asymptotiquement efficace. (loi des grands nombres)

## 3 Théorie générale de l'estimation

### 3.1 Estimateur linéaire en moyenne quadratique (ELMQ)

#### Définition

Un ELMQ fournit une estimée de la forme

$$\hat{\theta} = HY + C$$

à partir de l'erreur quadratique moyenne  $E[\|\hat{\theta}\|^2] = E[\hat{\theta}\hat{\theta}^T] = P_{\hat{\theta}}$

**Concept**  $H$  et  $C$  tel que  $P_{\hat{\theta}}$  minimal.

$$(1) \quad \frac{\partial P_{\hat{\theta}}}{\partial H} = 0 \quad \text{et} \quad (2) \quad \frac{\partial P_{\hat{\theta}}}{\partial C} = 0$$

**Proposition**

$$1) \quad \left[ \begin{array}{l} \frac{\partial P_{\hat{\theta}}}{\partial H} = 2E[HY + C - \theta] = 2E[\tilde{\theta}] = 0 \\ \text{L'ELMQ est un estimateur non biaisé.} \end{array} \right.$$

et donc :

$$\begin{aligned} C &= -Hm_Y + m_{\theta} \\ \hat{\theta} &= H(Y - m_y) + m_{\theta} \\ \tilde{\theta} &= H(Y - m_y) - (\theta - m_{\theta}) \end{aligned}$$

**Proposition**

$$2) \quad \left[ \begin{array}{l} \frac{\partial P_{\hat{\theta}}}{\partial C} = 2E[(HY + C - \theta)Y^T] = 2E[\tilde{\theta}Y^T] = 0 \\ \tilde{\theta} \perp Y \text{ quand la puissance est minimale, } \tilde{\theta} \text{ et } Y \text{ sont d\'ecorr\'el\'ees, on a} \\ \text{extrait toute l'information commune.} \end{array} \right.$$




FIGURE 4.3 – Représentation des paramètres

De plus :

$$\begin{aligned} E[\tilde{\theta}Y^T] &= E[\tilde{\theta}(Y - m_Y)^T] \\ &= E[(H(Y - m_Y) - \theta - m_{\theta})(Y - m_y)^T] \\ &= HC_{yy} - C_{\theta Y} = 0 \implies H = C_{\theta Y}C_{YY}^{-1} \end{aligned}$$

on a donc

$$\boxed{\hat{\theta} = C_{\theta Y}C_{YY}^{-1}(Y - m_Y) + m_{\theta}}$$

**Remarque** L'ELMQ nécessite des connaissances du premier et du second ordre sur  $\theta$  et  $Y$ .

**Proposition**

$$C_{\tilde{\theta}\tilde{\theta}} = C_{\theta\theta} - C_{\theta Y} C_{YY}^{-1} C_{Y\theta}$$

La corrélation entre  $\theta$  et  $Y$  permet de diminuer l'ELMQ.

## 3.2 Estimateur Bayésiens

### 3.2.1 Fonction coût/pénalité

**Définition**

On appelle fonction de coût ou fonction de pénalité une fonction qui mesure l'erreur entraînée par la prise de la valeur  $\tilde{\theta}$  pour  $\theta$ .

$$C(\hat{\theta}, \theta) \geq 0 \quad \text{ou encore} \quad C(\tilde{\theta}) \geq 0$$

On prendra le plus souvent une « bonne » fonction (continue, paire, croissante ...)

**Exemple de coût** on représente les fonctions de coût usuelles :




FIGURE 4.4 – Représentation des fonctions de coût classique

**Définition**

On appelle estimateur bayésien l'estimateur qui minimise le coût moyen :

$$\begin{aligned} E_{\theta,Y}[C(\hat{\theta}, \theta)] &= \int_{\mathbb{R}^{m+n}} C(\hat{\theta}, \theta) f_{\theta Y}(\theta, y) d\theta dy \\ &= \int_{\mathbb{R}^m} \left( \underbrace{\int_{\mathbb{R}^n} C(\hat{\theta}, \theta) f_{\theta|Y=y}(\theta) d\theta}_{E_{\theta|Y}[C(\hat{\theta}, \theta)]} \right) f_Y(y) dy \end{aligned}$$

On minimise donc  $E_{\theta|Y}[C(\hat{\theta}, \theta)]$  à coût conditionnel donné

$$\hat{\theta}_B = \arg \min_{\hat{\theta}} E_{\theta|Y}[C(\hat{\theta}, \theta)]$$

**3.2.2 Estimateur du maximum a posteriori (MAP)**

On considère un coût uniforme.

**Définition**

En prenant:

$$\begin{aligned} E_{\theta|Y}[C(\hat{\theta}, \theta)] &= \int_{\mathbb{R}^m} (1 - \Pi_{\Delta}(\tilde{\theta})) f_{\theta|Y=y}(\theta) d\theta \\ &= 1 - \int_{\hat{\theta}-\Delta/2}^{\hat{\theta}+\Delta/2} f_{\theta|Y=y}(\theta) d\theta \\ &\simeq 1 - \Delta^n f_{\theta|Y=y}(\hat{\theta}) \end{aligned}$$

Soit

$$\hat{\theta}_{MAP} = \arg \max_{\theta} f_{\theta|Y=y}(\theta)$$

**Lien MAP-MV** on a  $f_{\theta|Y=y}(\theta) f_Y(y) = f_{\theta Y}(\theta, y)$ . Avec  $f_{\theta}(\theta) = C^{ste}$  quand  $f_{\theta Y}(\theta, y)$  à une valeur significative (ie  $C_{\theta\theta}$  grand /  $\sigma_{\theta}$  grand) alors :

$$\arg \max f_{\theta|Y=y}(\theta) \simeq \arg \max f_{Y|\Theta=\theta}(y)$$

On considère alors que  $\theta$  est un paramètre aléatoire mais très mal connu. (ddp uniforme sur un interval très grand, peu d'infos sur  $\theta$ ).

cf. TD « file d'attente »

**Exemple et Application** On considère  $\theta$  scalaire aléatoire avec :  $Y_i = \theta + B_i$  Avec :

$$\begin{cases} B \hookrightarrow \mathcal{N}(0, C_{BB}) \\ \Theta \hookrightarrow \mathcal{N}(m_\theta, \sigma_\theta^2) \\ B \perp \Theta \end{cases}$$

**Rappel** MC=MV avec : 
$$\begin{cases} m_B = 0 \\ \hat{\theta}_{MV} = \hat{\theta}_{MC} = \frac{\sum_{i=1}^m Y_i}{m} \\ E[\hat{\theta}_{MV}] = E[\theta] = m_\theta \text{ et } \sigma_{\hat{\theta}_{MV}} = \frac{\sigma_B}{m} \end{cases}$$

On a donc :

$$f_{Y|\theta}(y) = f_B(Y - A\theta) = \prod_{i=1}^m f_{B_i}(Y_i - \theta) = C_1 \exp\left(-\frac{1}{2} \frac{\sum (Y_i - \theta)^2}{\sigma_B^2}\right)$$

Or

$$f_{\theta|Y=y}(\theta) = \frac{f_{Y|\theta}(y)f_\theta(\theta)}{f_Y(y)} = C_2 \exp\left(-\frac{1}{2} \underbrace{\left[\frac{\sum (Y_i - \theta)^2}{\sigma_B^2} + \frac{(\theta - m_\theta)^2}{\sigma_\theta^2}\right]}_{J_{MAP}}\right)$$

Le critère est ici une forme quadratique, donc :

$$\hat{\theta}_{MAP} = \arg \max f_{\theta|Y=y}(\theta) = \arg \min J_{MAP}(\theta, Y)$$

Alors on a la CNS :

$$\frac{dJ_{MAP}}{d\theta} = 0 = 2 \left[ -\sum_{i=1}^m \frac{Y_i - \theta}{\sigma_b^2} + \frac{(\theta - m_\theta)^2}{\sigma_\theta^2} \right]$$

Soit une expression barycentrique :

$$\hat{\theta}_{MAP} = \frac{\frac{m}{\sigma_B^2} \sum \frac{Y_i}{m} + \frac{m_\theta}{\sigma_\theta^2}}{\frac{m}{\sigma_B^2} + \frac{1}{\sigma_\theta^2}}$$

Donc :

### Proposition

$$E[\hat{\theta}_{MAP}] = m_\theta$$

L'estimateur est non biaisé. De plus :

$$\sigma_{\hat{\theta}_{MAP}}^2 = \frac{1}{\frac{1}{\sigma_{MV}^2} + \frac{1}{\sigma_\theta^2}} < \begin{cases} \sigma_\theta^2 \\ \sigma_{MV}^2 \end{cases}$$

On a fait mieux en prenant en compte toutes les sources d'informations.

### Remarque

- Si  $\sigma_\theta \gg \sigma_{MV}$  alors  $\hat{\theta}_{MAP} \simeq \hat{\theta}_{MV}$  (ce qui arrive pour  $\sigma_B$  ou  $m$  grand)
- Si  $\sigma_\theta \ll \sigma_{MV}$  et  $\hat{\theta}_{MAP} \simeq m_\theta$  (l'observation apporte peu d'info)

### 3.2.3 Estimateur en moyenne quadratique (EQM)

#### Définition

On le cout moyen de l'EQM:

$$C(\hat{\theta}, \theta) = (\hat{\theta} - \theta)^T M (\hat{\theta} - \theta)$$

Avec  $M > 0$ . On cherche a minimiser le cout moyen mais sans contrainte de linéarité avec une matrice de pondération qui peut prendre en compte des facteurs d'échelles ou des unités différentes.

**Etude de l'estimateur** On veut minimiser  $E_{\Theta|Y}[C(\hat{\theta}, \theta)]$

$$\begin{aligned} \nabla_{\hat{\theta}} E_{\Theta|Y}[C(\hat{\theta}, \theta)] &= 0 \\ E_{\Theta|Y}[2M(\hat{\theta} - \theta)] &= 0 \\ 2ME_{\Theta|Y}\left[\underbrace{\hat{\theta}}_{h(y)}\right] - E_{\Theta|Y}[\theta] &= 0 \\ 2M(\hat{\theta} - E_{\Theta|Y}[\theta]) &= 0 \\ \hat{\theta}_{MQ} &= E_{\Theta|Y}[\theta] \\ &= \int_{\mathbb{R}^n} \theta f_{\theta|y}(\theta) d\theta = h(Y = y) \end{aligned}$$

Par conséquent :  $E[\hat{\theta}_{MQ}] = E[\theta]$ . on a un estimateur non biaisé.

**Remarque** Si  $f_{\theta|Y}$  possède un axe de symétrie (ex : gaussienne) :

FIGURE . ( $\hat{\theta}_{MQ} = \hat{\theta}_{MAP}$  dans le cas gaussien. Différent avec deux bosses.)

Dans le cas général la contrainte de linéarité pour l'ELMQ conduit à une valeur plus grande qu'avec l'EQM. Dans le cas gaussien :  $\hat{\theta}_{ELMQ} = \hat{\theta}_{MQ}$ , mais  $\hat{\theta}_{MQ}$  nécessite plus de connaissance (ddp).

### 3.2.4 Estimateur en valeur absolu

#### Définition

on s'intéresse au cas  $n = 1$  (un paramètre) On choisit le cout moyen :

$$C(\hat{\theta}, \theta) = |\hat{\theta} - \theta|$$

Alors :

$$E_{\Theta|Y}[C(\hat{\theta}, \theta)] = \int_{-\infty}^{\hat{\theta}} (\hat{\theta} - \theta) f_{\theta|Y=y}(\theta) d\theta - \int_{\hat{\theta}}^{+\infty} (\hat{\theta} - \theta) f_{\theta|Y=y}(\theta) d\theta$$

Donc :

$$\begin{aligned} 0 &= \nabla_{\hat{\theta}} E_{\theta|Y}[C(\hat{\theta}, \theta)] \\ &= \dots \\ &= \int_{-\infty}^{\hat{\theta}} f_{\theta|Y=y}(\theta) d\theta - \int_{\hat{\theta}}^{+\infty} f_{\theta|Y=y}(\theta) d\theta \end{aligned}$$

### **Proposition**

L'estimée est alors  $\hat{\theta}_{VA}$  tel que :

$$\int_{-\infty}^{\hat{\theta}} f_{\theta|Y=y}(\theta) d\theta = \int_{\hat{\theta}}^{+\infty} f_{\theta|Y=y}(\theta) d\theta$$

On parle de médiane a posteriori. Le résultat se généralise pour tout  $n$ .

**Remarque** Dans le cas où  $f_{\theta|Y=y}(\theta)$  possède un axe de symétrie (ex gaussienne) on a :

$$\hat{\theta}_{VA} = \hat{\theta}_{MV} \stackrel{\max}{\downarrow} \hat{\theta}_{MAP}$$

**Exemple** Localisation d'un véhicule / Ellipsoïde de confiance (cf poly).

## 4 Conclusion

- L'estimateur statistique dépend des connaissances a priori, de la complexité des calculs et de la robustesse attendue.
- Dans certains cas particuliers/ limites on retrouve des estimateurs intuitifs / empirique.
- La loi normale joue un rôle important (hypothèses qui se justifie par la loi des grands nombres) : les calculs sont simplifiés et conduisent au même résultat.